

四个顶级大模型 同一道量化题

相同数据、相同手续费、相同目标函数,各自用官方 CLI 写一套能做多也能做空的策略。

然后扔进一个它们从没见过的年份 —— 那一年,大盘跌了
45%。

Kimi K3 · Kimi Code

Claude Opus 5 · Claude Code

Claude Fable 5 · Claude Code

DeepSeek V4 Flash · Codex

样本外区间 2025-07 ~ 2026-07 标的 20 个 U 本位永续 手续费 0.06% / 边

杠杆 1x 全程 dry-run 模拟盘

所有数字为独立复现(统一 fee、`--cache none`),模型自报仅用于比对。本报告不构成投资建议。

— 01 / 摘要

每个都做对了一半

没有一个两样都对

四个模型在验证集上的夏普是 1.24、1.34、1.87、1.93。
任何人看到这四个数都会说:能用。换到样本外那一年,四个全部由正转负,没有一个例外。

四个顶级 AI,各做对了一半

没有一个两样都对

Fable 5

选股对了,仓位错了

alpha +7.9% / 净敞口 34%

Opus 5

仓位对了,选股错了

beta 0.03 / alpha -20.2%

DeepSeek

两样都不功不过

alpha $\approx$ 0 / 回撤最小 14%

Kimi K3

两样都没做对

alpha -29.5% / DSR 0.094

核心结论

看「亏了多少」得不出结论。把收益拆成 alpha 和 beta 之后,四个模型露出四张完全不同的脸。

有的选股是对的但仓位押错了(Fable),有的仓位是对的但选股失效(Opus),有的两样都不功不过(DeepSeek),有的两样都没做对(Kimi)。下面每一条都会给出可复现的数据依据。

	KIMI K3	OPUS 5	FABLE 5	DEEPSEEK
样本外收益	-29.8%	-19.6%	-7.5%	-7.1%
年化 alpha	-29.5%	-20.2%	+7.9%	-0.2%
一句话	两样都没做对	仓位对了 选股错了	选股对了 仓位错了	不功不过 风控最好



六个维度打完分，四家拉开了 3.2 分的差距。但谁是谁，先不揭晓——你得先看到我是怎么考的，那个分数才值得信。

先卖个关子

那到底谁赢了？

排名和总分放在**第 11 节**。在那之前,先看考题、看它们各自怎么答的、看样本外把它们打成什么样。**不知道怎么考的,分数就没有意义。**

— 02 / 评测方法

考题与评价框架

一场考试公不公平,全看规则划得清不清楚

锁死 · 四条

- **标的池** —— 20 个 U 本位永续,BTC 到 AAVE 全部固定。不许按表现挑币(幸存者偏差)
- **成本** —— 每边 0.06%,一个来回 0.12%,资金费真实计入
- **目标函数** —— 我提供代码,不许自己写。它就是这道题本身
- **杠杆 1 倍,必须双向** —— 只做多的直接判负

🔒 开放 · 六条

- **策略家族** —— 横截面、趋势、均值回归、突破,能论证就行
- **时间周期** —— 30m / 1h / 4h / 1d 四种数据都备好,自选
- **进出场逻辑、回撤控制、换手控制** —— 全自定
- **搜索轮数** —— 上限 2000,用多少自己判断

设计意图

轮数上限放开是**故意的** —— 「搜得越多越好」本身就是陷阱。

你搜的次数越多,靠运气刷出漂亮回测的概率就越大。用多少轮,本身就是判断力的一部分,后面第 3 层用 Deflated Sharpe 专门算这笔账。

公平性:三件必须做的事

1. **Prompt 逐字相同**。不是「意思差不多」,是一个字都不差的同一份 GOAL.md。
2. **用英文写**。中文可能偏袒 Kimi(月之暗面是中文团队);术语原生表达就是英文;和 Freqtrade 工具链同语言。前沿模型中英能力已经很接近,核心理由是第一条 —— 中立。
3. **样本外数据物理搬走**。不是靠 prompt 说「你别看」,是把 2025-07 之后的数据放到另一个盘符 `D:\freqtrade_locked\`。模型就算跳过所有权限、自由执行任何命令也扫不到。

四个环境字节级一致 —— 同一个 Docker 镜像、同一份 config、同一份数据,四个终端跑 md5sum 哈希完全相同。第 3 条不做,后面的结果全是假的。

评价框架:先淘汰,后打分

层	看什么	不合格的后果
第 1 层 • 硬门槛	跑通 / 有成交 / 双向 / 未改手续费 / 未动脚手架	任一条 → 直接出局
第 2 层 • 表现	收益、夏普、索提诺、卡玛、回撤、换手	计入评分
第 3 层 • 稳健性(权重最高)	三段一致性、蒙特卡洛重排、Deflated Sharpe	计入评分
第 4 层 • 作弊检测	因果检查(全量 vs 截断)	不通过 → 直接出局
第 5 层 • 工程与判断力	代码质量、自评诚实度、怎么选的参数	计入评分

一个容易拿错的口径:Freqtrade 报告里夏普有两行 —— 按每笔交易算、按每日资金曲线算,两者能差 2.5 倍。同时持仓 20 个的时候交易互相重叠,按每笔算会虚高。本报告一律取「daily wallet balance」那一行。

第 1 层 硬门槛 + 第 4 层 作弊检测:四家全过

	Kimi K3	Opus 5	Fable 5	DeepSeek
编译 / 跑通 / 有成交				
多空双向都用了	104 / 87	167 / 157	386 / 139	213 / 194
杠杆 1x 未超				
脚手架未篡改				
手续费未偷改(6bps)				
交付 6 文件齐全				
因果检查(全量 vs 截断)	PASS	PASS *	PASS	PASS

* Opus 的 factor_score 走 dataprovider,标准截断法不适用,改用框架级检验(两个结束日期的回测对比重叠期决策)

结论

四家全部通过,没有一家作弊。

都跑通了、都有成交、都真的用了做空(不是挂个空头逻辑不触发)、都没动脚手架、都没偷改手续费、交付文件都齐。这一步全过,后面的分数才有意义。

因果检查是怎么做的

把每家的信号计算抽出来,对同一个时间点,用全量数据算一遍、用截断到那一刻的数据再算一遍。两个结果不一样,就说明它用了未来数据。

六个时间点上,差异全部是 **0.00e+00**。

两个技术细节:

- Opus 的 `factor_score` 走 dataprovider,标准截断法不适用。改用框架级检


验:两个不同结束日期的回测比对重叠期决策 —— 161 vs 162 笔,唯一差异开在短区间最后一天,是边界效应不是未来函数。

· Freqtrade 自带的 `lookahead-analysis` 对横截面策略会误报 —— 它把边界 bar 的排名变化当成偏差。全量 vs 截断的对照测试证明是假阳性。

— 04 / 自主选择

没有一家跑满 2000 轮

题目全开放,它们自己选了什么




发现 1

上限给了 2000 轮,四家实际只用了 300、300、400、500。

而且从收敛曲线看,它们停下来的时候曲线早就平了——不是算力不够,是**主动判断继续搜没有收益、只有过拟合风险**。这一点四家都做对了。

周期越快,手续费吃得越狠——四家都没碰 30 分钟



发现 2

四家都没碰 30 分钟。Opus 和 Fable 选 4 小时,Kimi 和 DeepSeek 选日线。

我自己做的对照实验说明了原因:同一个因子,30 分钟不控换手一年 12,745 笔亏 44.7%;换成 4 小时加最短持仓,436 笔反而赚 3.28%。**周期越快,手续费吃得越狠——**这是量化最基础也最容易被忽略的一课,四家都答对了。

四家的自主选择				
	KIMI K3	OPUS 5	FABLE 5	DEEPSEEK
CLI	Kimi Code	Claude Code	Claude Code	Codex
时间周期	1d	4h	4h	1d
策略家族	横截面	横截面	横截面	横截面
搜索轮数 (上限 2000)	400	300	300	500
策略代码行数	47	210	72	70
设计文档行数	108	343	113	160
样本外交易笔数	191	324	525	407

四家全部选了横截面家族 —— 题目已经开放到任意家族,但没有一家去做趋势或均值回归。这本身也是个信号。

— 05 / 第 5 层 · 判断力

三家拒绝了最优参数 一家接住了

这是四家差距最清晰的一处

你现在想的大概是「AI 就会瞎调参,肯定往回测最漂亮的方向凹」。我一开始也这么想。结果完全不是。

第 5 层 判断力:三家拒绝了验证集最高分,一家接住了



发现 1

三家主动放弃了验证集分数最高的那组参数。

Opus 在设计文档里算出训练集与验证集夏普的相关性只有 $r = 0.21$,结论是「验证集的排名基本上是噪音」;最高那组比均值高 2.5 个标准差,它写道——「取它就等于取 300 次抽样里最大的那个噪音」,改用 12 近邻平台选参法。

Kimi 弃掉的那组是 训练 -0.38 / 验证 2.68,评价是「这正是这道题定义的失败模式」。

Fable 的说法:「过度搜索就是在过拟合验证集」。

发现 2

DeepSeek 是唯一直接采用验证集最高分那组的。
它的最优轮是 验证 2.25 / 训练 0.65 —— 跟 Kimi
明确点名要避开的,是同一类反向落差。


发现 3

四家的 r 差距很大:**0.54 / 0.21 / -0.06 / -0.28**。
r 越接近 0,说明这家的验证集排名越接近纯噪音 —— 它调参时
能依靠的信息越少。记住这个顺序。揭盲之后我们回来对一下,
看它能不能提前预言成败。

TRAIN/VALID	相关性 R	验证集排名的信噪比	最优轮	实际采
Fable 5	+0.54	四家最高	e273	e276(拒绝最佳)
Opus 5	+0.21	弱	e254	e233(拒绝最佳)
DeepSeek	-0.06	≈ 纯噪音	e408	e408(直接采用)
Kimi K3	-0.28	负相关	e370	e235(拒绝最佳)

r 越接近 0,说明验证集排名越接近纯噪音 —— 这时候「挑验证集最高分」等于挑运气。

四个全部由正转负



圆点 = 验证集(模型调参用的),三角 = 样本外(它们没见过的一年)。

结论

没有一个例外。验证集 1.24 / 1.34 / 1.87 / 1.93,样本外 -3.71 / -1.42 / -0.62 / -0.62。

注意夏普最高的那家(DeepSeek 1.93)并没有摔得最惨 —— **验证集排名和样本外排名几乎没有关系**,这正是「验证集已经是训练集的一部分」的直接证据。

还记得上一节那个 r 吗?把它和样本外成绩排在一起——几乎同序。

Fable $r = +0.54$ 四家最高 → 样本外 最好

Opus $r = +0.21$ → 样本外第三

DeepSeek $r = -0.06$ → 样本外第二

Kimi $r = -0.28$ 负相关 → 样本外 垫底


这意味着:验证集的信噪比本身,就是一个能在揭盲之前看出成败的指标。你不用等一年,搜完参数当场就能算。(四个样本,只能算强提示,不是定论)

样本外一年:2025-07 → 2026-07



样本外一年的净值曲线,灰线是大盘(20 币等权)。四家都跑赢了大盘,但都是负的。

样本外:多空两侧各赚了多少(大盘 -45%)



最 刺 眼 的 一 条

Kimi 的空单在跌 45% 的熊市里,还亏了 1.3%。


另外三家的空头一侧都赚了(+11.1% / +9.2% / +15.3%), 只有它该赚钱的一侧没赚到。而且它的亏损**统计显著**($p = 0.0008$)——四家里唯一一个「亏得不像运气」的。

第 2 层完整成绩

	KIMI K3	OPUS 5	FABLE 5	DEEPSEEK
训练 集收 益 / 夏普	+70.5% / 0.92	+65.2% / 0.78	+71.3% / 0.92	+67.1% / —
验证 集收 益 / 夏普	+39.6% / 1.24	+46.0% / 1.34	+54.6% / 1.87	+71.1% / 1.93
样本 外收 益	-29.8%	-19.6%	-7.5%	-7.1%
样本 外夏 普	-3.71	-1.42	-0.62	-0.62
最大 回撤	33.9%	24.3%	23.1%	14.0%
跑赢 大盘	+16 点	+28 点	+40 点	+39 点
多头 / 空 头	-28.5% / -1.3%	-30.6% / +11.1%	-16.8% / +9.2%	-22.4% / +15.3%
p 值	0.0008	0.148	0.526	0.613

这个成绩 有多少是搜出来的运气

权重最高的一层




结论

Kimi 搜了 400 轮, 验证夏普 1.57 —— 而纯靠运气就能刷到 2.55。

运气基线比它实际成绩还高。 Deflated Sharpe = 0.094, 意思是这个成绩在统计上完全不显著。另外三家的 DSR 在 0.7~0.87 之间, 虽然都没过 0.95 门槛, 但至少跑赢了自己的运气基线。

蒙特卡洛重排 5000 次:这套策略赚钱的概率有多大



交叉验证

蒙特卡洛给出的排序和 DSR 一致:**Fable 8.9% 是唯一非零的,Kimi 是干净的 0%。**

两个方法原理完全不同(一个是解析式的多重检验校正,一个是对成交序列做分块重采样),结论却指向同一家 —— 这种交叉一致性比任何单一指标都可信。

	KIMI K3	OPUS 5	FABLE 5	DEEPSEEK
Deflated Sharpe	0.094	0.868	0.715	0.868
观察夏普 / 运气基线	1.57 / 2.55	1.62 / 0.78	1.98 / 1.53	2.18 / 1.44
蒙卡 prob(profit)	0.0%	0.1%	8.9%	0.9%


一年赚了 7.9%,却亏了 7.5%

本报告最核心的一节

看到「全亏了」就下结论,是这期最容易犯的错。**亏多少不重要,重要的是亏在哪一部分。**

把每家的逐日盯市权益对大盘做回归,收益拆成两块 ——


alpha = 选股本身创造的超额 · **beta** = 跟着大盘涨跌被动带走的部分



核心发现

Table 5 是四家唯一造出正 alpha 的(+7.9%)。它亏钱纯粹因为 34% 的净多头敞口撞上熊市,被 beta 拖走 14 个点。

换句话说 —— 它的选股是真本事,仓位押错了方向。如果做成真中性,这一年大约是 +6.5%。(事后归因,反事实推算)



「各做对了一半」的量化版本。

Fable 5 —— 唯一正 alpha,但净敞口 34% 全场最高

Opus 5 —— beta 0.03 / R^2 0.03,四家唯一做到真市场中性,大盘跌对它几乎没影响,但选股是负的

DeepSeek —— alpha ≈ 0 ,亏的几乎全是 beta,但回撤控制最好

Kimi K3 —— 负 alpha 最深,选股方向反了

ALPHA / BETA 分解(逐日盯市权益回归大盘)


	BETA	R^2	年化 ALPHA	实际收益	BETA 拖累	净敞口
Kimi K3	0.12	0.30	-29.5%	-29.8%	-5.5%	17.7%
Opus 5	0.03	0.03	-20.2%	-19.6%	-1.3%	8.1%
Fable 5	0.31	0.76	+7.9%	-7.5%	-14.0%	34.1%
DeepSeek	0.15	0.38	-0.2%	-7.1%	-6.8%	15.0%

— 09 / 环境归因

真正的杀手不是调参技巧

是市场变天

真正的杀手不是调参技巧,是市场变天



结论

训练和验证都是牛市,样本外一进熊市,四个策略一起趴下。

而且不只是方向变了 —— 币之间越来越同涨同跌(相关性 0.55 → 0.67),可供横截面策略捕捉的差异收窄了 35%(离散度 60.7% → 39.3%)。四家全部选了横截面家族,而这正是横截面最难受的环境。

区间	长度	大盘年化收益	平均相关性	横截面离散度
训练 2021-01 ~ 2024-06	3.5 年	+69.8%	0.55	60.67%
验证 2024-07 ~ 2025-06	1 年	+28.6%	0.62	48.99%
样本外 2025-07 ~ 2026-07	1 年	-45.0%	0.67	39.28%


训练段 3.5 年,统一年化后才可比。离散度 = 每日横截面标准差的均值 × √365。

最贵的比最便宜的 贵 350 倍

两种口径,必须先说清楚。

- DeepSeek / Kimi —— 走 API Key,后台是**真金白银的实际扣费**,已用逐请求明细核对
- Opus 5 / Fable 5 —— 走 Claude Code 会员,后台**查不到**(会员用量不进 API 账单)。数字由本地日志 token 用量 × 公开单价折算,是**等效成本**,实际额外掏钱为 0

同一道题,最贵的比最便宜的贵 350 倍




发现 1

Fable 的标价是 Opus 的整整两倍,总账单却只有 Opus 的四分之一。

差别不在价格,在 token 总量 —— Opus 烧了 5906 万,Fable 只烧了 736 万,八倍。Opus 是四个里最勤奋的,前后写了 5 个策略文件、343 行设计文档,一路试一路淘汰。真正决定账单的不是单价,是它到底吞了多少 token。大家挑模型习惯只看前半截。

花的钱 vs 造出来的 alpha:两者没有关系



花的钱和产出,完全没有关系。

花最多的 Opus alpha 是 -20.2%;花第二少的 Kimi alpha -29.5% 最差;唯一造出正 alpha 的 Fable 花的钱排在中间。这条曲线上找不到任何单调关系。

那贵的钱买到什么了?**买到了工程深度,只是没换成收益**——Opus 的代码质量和方法论自省都是四家天花板。

	DEEPSEEK	KIMI K3	FABLE 5	OPUS 5
成本	¥1.04	¥15.62	¥94.9	¥363.3
口径	平台实扣	平台实扣	日志折算	日志折算
API 调用数	124	71	109	330
Token 总量	13.8M	4.36M	7.36M	59.1M
实际干活时长	61 分	42 分	12 分	95 分
工作段数	1	2	2	3 (跨夜)
每分成本	¥0.15	¥3.67	¥12.26	¥50.39

每分成本 = 总成本 ÷ 五维加权分(剔除性价比自身,避免循环)。


两个必须说的口径问题:

- DeepSeek 那一块零四有水分。它 1380 万 token 里 96.7% 是缓存命中,而 DeepSeek 缓存命中价是每百万两分钱。换个缓存命中率低的任务,这个数完全不一样——别拿它当通用结论。
- 「12 小时」是个坑。Opus 的会话跨度 730 分钟,但其中 673 分钟是空档(最

长一段 430 分钟 = 我在睡觉)。真正在跑的只有 95 分钟。拿会话首尾时间当耗时能高估七倍多。

— 11 / 综合评分

六个维度,总分排行



维度	权重	KIMI K3	OPUS 5	FABLE 5	DEEPSEEK
稳健性	0.25	2	6	7	6
无作弊	0.15	10	10	10	10
表现(风险调整,样本外)	0.25	1	4	8	7.5
代码质量	0.15	3	9	5	5
解释诚实 / 判断力	0.15	9	10	9	6
性价比(每分成本)	0.05	7	2	5	10
加权总分		4.4	7.0	7.6	7.0



Fable 5 —— 唯一有真 alpha

7.6

样本外 -7.5%(跑赢大盘 40 点),**年化 alpha +7.9%**,**四家唯一为正**;蒙卡 8.9% 唯一非零;验证集信噪比最高($r = 0.54$)。

扣分:净敞口 34% 全场最高、beta 0.31、换手最高。**选股对了,仓位错了。**



DeepSeek V4 Flash —— 收益最好、回撤最小、最便宜

7.0

样本外 -7.1% 最好、回撤仅 14.0% 四家最小、空单 +15.3% 最强、DSR 0.868 并列最高、成本 ¥1.04。

扣分:alpha ≈ 0 ,「没做错什么,也没创造什么」;唯一直接采用最优轮参数的。



Opus 5 —— 方法论最严谨、最接近真中性

7.0

beta 0.03 / R^2 0.03,四家唯一做到真市场中性;DSR 0.868 并列最高;design.md 里 $r = 0.21$ 的诊断是四家最深的。

扣分:alpha -20.2%,选股本身失效;成本 ¥363 是 DeepSeek 的 350 倍。仓位对了,选股错了。



Kimi K3 —— 周期选得最省,但选股失效

4.4

日线把换手压到最低(191 笔,成本最省),代码最简洁(47 行)。

扣分:alpha -29.5% 最差;空单在熊市倒亏 1.3%;DSR 0.094、蒙卡 0%、 $p = 0.0008$ 亏得统计显著。

DeepSeek 与 Opus 实质并列第二(7.03 vs 6.95,差值在四舍五入以内)。两家强项完全不同:DeepSeek 赢在成绩与成本,Opus 赢在工程与方法论。

性价比这一项我改过三次口径——①按公开标价 ②按实测等效成本 ③按每分成本。三次口径下总排名完全一致,说明结论对成本口径不敏感。

— 12 / 诚实披露

这份报告的五个局限

1. **样本外那一年是熊市**(-45%),训练和验证都是牛市。这是最诚实的压力测试,但不是中性样本。换个年份结论可能不一样。
2. **幸存者偏差**。这 20 个币是 2026 年回头挑的,2021 年就退市的不在池子里。所有回测都躲不掉,包括我这个。
3. **滑点乐观**。扁平 0.06%,没有市场冲击模型。真实交易只会更差。
4. **样本外仅 1 年 × 20 个高相关标的**,统计上偏薄。蒙卡和 DSR 只能部分兜底。
5. **成本四家口径不完全一致**。DeepSeek / Kimi 是平台实扣,Opus / Fable 是会员无账单按日志折算;各厂商缓存计价规则差异极大,不宜精确到个位数解读。

雷达图那六个分数里,稳健性、表现、成本有客观依据(DSR / 蒙卡 / alpha-beta / 实测账单);代码质量和解释诚实是我读完代码和文档后的主观打分。依据全部放出来了,你可以不同意。

下次看到夏普 1.9 的回测 先问三个问题

样本外 跑过没有？

训练和验证都是它调参用过的。没有真正的盲测，数字不算数。

搜了 多少轮？

搜得越多，靠运气刷出漂亮回测的概率越大。用 DSR 算这笔账。

收益里 多少是 beta？

把权益对大盘回归。beta 高的话，你赚的只是行情，不是本事。

最终结论

四个顶级 AI，防过拟合的功课都做了 —— 主动少搜、拒绝最优参数、自己承认验证集被污染。然后它们还是全亏了。

说明真正的杀手不是调参技巧，是市场变天。 这三个问题，这份报告里的每个数字都教了你怎么算。

所有代码、评分表、四家的完整交付物我都会放出来，你可以自己复现。

下期把这套方法搬到 A 股，用 QMT 和通达信的数据跑一遍。